

1 Streszczenie

1.1 Streszczenie

Praca inżynierska dotyczy projektu inteligentnego systemu zarządzania zasobami cyfrowymi z wykorzystaniem wyszukiwania semantycznego. System ten ma na celu umożliwienie efektywnego przechowywania, organizowania oraz przeszukiwania plików cyfrowych w różnych formatach. Kluczowym elementem rozwiązania jest zastosowanie mechanizmów inteligentnego wyszukiwania, które pozwalają użytkownikowi odnajdywać dokumenty nie tylko na podstawie słów kluczowych, ale również znaczenia zapytań oraz podobieństwa treści.

System obejmuje funkcje dodawania i zarządzania zasobami, ich klasyfikacji za pomocą kategorii i tagów oraz edycji metadanych. Istotną rolę odgrywa również kontrola wersji, wykrywanie duplikatów oraz możliwość udostępniania plików innym użytkownikom. Rozwiązanie wspiera także filtrowanie i sortowanie danych, co ułatwia ich organizację i szybkie odnajdywanie potrzebnych informacji.

Dodatkowo system umożliwia pobieranie zasobów z opcjonalną konwersją formatu oraz automatyczne generowanie miniatur dokumentów. Całość uzupełniają mechanizmy uwierzytelniania i autoryzacji użytkowników, które zapewniają bezpieczny dostęp do zasobów. Projekt uwzględnia zarówno aspekty funkcjonalne, jak i wymagania jakościowe, takie jak wydajność, bezpieczeństwo i użyteczność systemu.

Słowa kluczowe: system zarządzania dokumentami, DMS, wyszukiwanie semantyczne, embeddingi, baza wektorowa, pgvector, PostgreSQL

1.2 Abstract

The engineering thesis focuses on the design of an intelligent digital asset management system utilizing semantic search. The system is intended to enable the efficient storage, organization, and searching of digital files in various formats. A key element of the solution is the use of intelligent search mechanisms that allow users to find documents not only based on keywords but also on the meaning of queries and content similarity. The system includes functions for adding and managing resources, classifying them using categories and tags, and editing metadata. Version control, duplicate detection, and the ability to share files with other users also play a significant role. The solution also supports filtering and sorting data, which facilitates organization and quick retrieval of needed information.

Additionally, the system allows for downloading resources with optional format conversion and automatic generation of document thumbnails. The system is complemented by user authentication and authorization mechanisms, which ensure secure access to resources. The project takes into account both functional aspects and quality requirements, such as performance, security, and usability of the system.

Keywords: document management system, DMS, semantic search, embeddings, vector database, pgvector, PostgreSQL

Spis treści

1	Streszczenie	1
1.1	Streszczenie	1
1.2	Abstract	1
2	Wstęp	4
3	Cel, zakres i podział pracy	5
3.1	Cel pracy	5
3.2	Zakres pracy	5
3.3	Podział pracy	6
3.3.1	Mateusz	6
3.3.2	Mateusz	6
3.3.3	Mateusz	6
4	Analiza rynku	7
4.1	Paperless-ngx	7
4.1.1	Główne cechy	7
4.1.2	Ograniczenia	7
4.2	OpenKM	9
4.2.1	Główne cechy	9
4.2.2	Ograniczenia	9
4.3	M-Files	10
4.3.1	Główne cechy	10
4.3.2	Ograniczenia	11
4.4	Wnioski	12
5	Projekt systemu	13
5.1	Specyfikacja wymagań funkcjonalnych	13
5.1.1	Dodawanie zasobów	13
5.1.2	Wyszukiwanie zasobów	13
5.1.3	Filtrowanie i sortowanie zasobów	13
5.1.4	Zarządzanie kategoriami i tagami	13
5.1.5	Zarządzanie zasobami	14
5.1.6	Udostępnianie i zarządzanie udostępnieniami zasobów	14
5.1.7	Kontrola wersji i wykrywanie duplikatów zasobów	14
5.1.8	Pobieranie zasobów z opcjonalną konwersją formatu	14

5.1.9	Generowanie miniaturk zasobów	14
5.1.10	Autoryzacja i uwierzytelnianie użytkowników	14
5.2	Specyfikacja wymagań niefunkcjonalnych	15
5.2.1	Wydajność (dla bazy zawierającej do 1000 dokumentów)	15
5.2.2	Pojemność	15
5.2.3	Bezpieczeństwo	15
5.2.4	Kompatybilność	15
5.2.5	Użyteczność	15
5.3	Hierarchiczny model funkcji	15
5.4	Historyjki użytkowników	17
5.4.1	Rejestracja i uwierzytelnianie użytkowników	17
5.4.2	Dodawanie dokumentów	17
5.4.3	Przeglądanie dokumentów	17
5.4.4	Wyszukiwanie dokumentów	17
5.4.5	Zarządzanie dokumentami i metadanymi	17
5.4.6	Pobieranie i konwersja dokumentów	17
5.4.7	Udostępnianie dokumentów	18
5.5	Scenariusze przypadków użycia	18
5.5.1	Pobieranie dokumentu z konwersją do formatu PDF.	18
5.5.2	Udostępnianie dokumentu po wyszukaniu semantycznym	19
5.6	Diagramy przypadków użycia	19
5.7	Diagramy procesów biznesowych	24
5.8	Diagramy przepływu danych	27
5.9	Diagram stanów	29
5.10	Diagram bazy danych	31

2 Wstęp

W dobie powszechnej cyfryzacji oraz dynamicznego rozwoju technologii informatycznych, efektywne zarządzanie informacją stało się jednym z kluczowych wyzwań stojących zarówno przed organizacjami, jak i użytkownikami indywidualnymi. Gwałtowny przyrost wolumenu generowanych danych sprawia, że tradycyjne metody przechowywania dokumentów w strukturach katalogów systemowych stają się niewystarczające. Prowadzi to do powstawania barier informacyjnych, trudności w utrzymaniu spójności wersji dokumentów oraz znacznego wydłużenia czasu potrzebnego na dotarcie do poszukiwanej wiedzy. Rozwiązaniem tych problemów są systemy zarządzania dokumentami klasy DMS (ang. *Document Management System*), które automatyzują procesy archiwizacji, kategoryzacji i kontroli dostępu do plików.

Tradycyjne systemy DMS opierają swoje mechanizmy wyszukiwania na sztywnych strukturach metadanych oraz klasycznym indeksowaniu pełnotekstowym. Podejście to, choć skuteczne w przypadku znajomości dokładnych fraz lub nazw plików, okazuje się bezużyteczne, gdy użytkownik formułuje zapytania w języku naturalnym lub poszukuje dokumentów powiązanych kontekstowo bądź znaczeniowo. Przeprowadzona analiza rynku wykazała istotną lukę technologiczną. Istniejące rozwiązania open-source, takie jak Paperless-ngx, oferują lekkość wdrożenia, lecz są pozbawione zaawansowanej analizy semantycznej treści. Z kolei rozbudowane systemy korporacyjne, na przykład M-Files, wprowadzają zaawansowane mechanizmy sztucznej inteligencji, jednak wiążą się z wysokim progiem wejścia, skomplikowaną konfiguracją oraz silną zależnością od zewnętrznych, zamkniętych ekosystemów chmurowych.

Niniejsza praca inżynierska stanowi odpowiedź na zidentyfikowane ograniczenia rynkowe poprzez zaprojektowanie, implementację oraz przetestowanie inteligentnego systemu DMS wykorzystującego nowoczesne metody wyszukiwania semantycznego. Istotą rozwijanego rozwiązania jest integracja tradycyjnych funkcji platformy DMS – takich jak kontrola wersji dokumentów, wykrywanie duplikatów na podstawie zawartości, taksonomia za pomocą kategorii i tagów.

Kluczowym elementem innowacji projektowanego systemu DMS jest autorska architektura bazy danych, która w ramach jednej instancji silnika PostgreSQL łączy cechy magazynu relacyjnego i wektorowego. Wykorzystanie rozszerzenia *pgvector* pozwala na składowanie matematycznych reprezentacji tekstu w postaci embeddingów o długości 2048 komponentów (*halfvec(2048)*), na które nakładane są wydajne indeksy HNSW. Dzięki temu system umożliwia błyskawiczne realizowanie zapytań opartych na podobieństwie cosinusowym, pozwalając na odnajdywanie dokumentów na podstawie ich rzeczywistego znaczenia oraz wyszukiwanie plików podobnych do wskazanego zasobu źródłowego.

Mając na uwadze rygorystyczne wymagania nefunkcjonalne dotyczące wydajności i pojemności, wszelkie operacje kosztowne procesowo zostały odizolowane od głównego wątku aplikacji i przeniesione do warstwy asynchronicznej. Procesy takie jak ekstrakcja tekstu, generowanie wektorów osadzenia przy użyciu zewnętrznego modułu AI Inference, konwersja formatów (np. transformacja plików DOCX do formatu PDF) oraz renderowanie graficznych miniatur dokumentów są zarządzane przez dedykowaną kolejkę zadań systemowych (*document_job_queue*). Bezpieczeństwo i skalowalność systemu zapewnia fizyczne odseparowanie metadanych od samych dokumentów, które wraz

3 Cel, zakres i podział pracy

3.1 Cel pracy

Celem pracy jest zaprojektowanie, implementacja oraz przetestowanie systemu zarządzania dokumentami (Document Management System), umożliwiającego przechowywanie, organizację, wyszukiwanie oraz udostępnianie zasobów cyfrowych. Projektowany system ma wspierać użytkowników w zarządzaniu dokumentami poprzez wykorzystanie zarówno klasycznych mechanizmów wyszukiwania, jak i wyszukiwania semantycznego opartego na reprezentacji wektorowej treści dokumentów.

System ma umożliwiać gromadzenie dokumentów w różnych formatach, zarządzanie ich metadanymi, kategoryzację, tagowanie oraz kontrolę wersji. Dodatkowo zasoby powinny być prezentowane w sposób ułatwiający ich identyfikację i przeglądanie, między innymi poprzez automatyczne generowanie miniaturek dokumentów. Użytkownik powinien mieć możliwość wyszukiwania dokumentów na podstawie zapytań w języku naturalnym oraz odnajdywania dokumentów podobnych pod względem treści i zawartości wizualnej.

System ma również zapewniać możliwość udostępniania zasobów za pomocą dedykowanych linków dostępowych oraz zapewniać możliwość konwersji dokumentów pomiędzy wybranymi formatami, co zwiększy elastyczność wykorzystania zgromadzonych zasobów.

Rezultatem pracy będzie działający prototyp systemu składający się z warstwy serwerowej, aplikacji webowej oraz aplikacji mobilnej, umożliwiający realizację zdefiniowanych wymagań funkcjonalnych i нефункциональных.

3.2 Zakres pracy

Zakres pracy obejmuje:

- analizę rynku istniejących systemów zarządzania dokumentami pod kątem dostępnych funkcjonalności oraz wykorzystywanych technologii,
- określenie wymagań funkcjonalnych i нефункциональных projektowanego systemu,
- opracowanie historyjek użytkowników oraz scenariuszy przypadków użycia,
- wykonanie diagramów procesów biznesowych BPMN,
- opracowanie diagramów projektowych, w tym diagramu przepływu danych (DFD), diagramu związków encji (ERD) oraz diagramu stanów,
- zaprojektowanie interfejsu użytkownika dla aplikacji webowej i mobilnej,
- dobór technologii wykorzystywanych do implementacji systemu,
- implementację warstwy serwerowej odpowiedzialnej za zarządzanie dokumentami, przetwarzanie plików oraz realizację wyszukiwania semantycznego,
- implementację aplikacji webowej umożliwiającej zarządzanie dokumentami,
- implementację aplikacji mobilnej zapewniającej dostęp do funkcjonalności systemu,
- implementację mechanizmów przechowywania dokumentów, zarządzania metadanymi, wersjonowania oraz udostępniania zasobów,
- implementację mechanizmów wyszukiwania dokładnego i semantycznego z wykorzystaniem reprezentacji wektorowej dokumentów,
- przeprowadzenie testów funkcjonalnych systemu,
- analizę uzyskanych wyników oraz sformułowanie wniosków końcowych.

3.3 Podział pracy

3.3.1 Mateusz

- Streszczenie (rozdział 1)
- Wstęp (rozdział 2)
- Cel, zakres i podział pracy (rozdział 3)
- Specyfikacja wymagań funkcjonalnych (podrozdział 5.1)
- Specyfikacja wymagań niefunkcjonalnych (podrozdział 5.2)
- Scenariusze przypadków użycia (podrozdział 5.5)
- Diagramy przypadków użycia (podrozdział 5.6)
- Diagramy przepływu danych (podrozdział 5.8)
- Projekt interfejsu graficznego (podrozdział 5.11)

3.3.2 Mateusz

- Hierarchiczny model funkcji (podrozdział 5.3)
- Diagramy przypadków użycia (podrozdział 5.6)

3.3.3 Mateusz

- Analiza rynku istniejących systemów zarządzania dokumentami (rozdział 4)
- Historyjki użytkowników (podrozdział 5.4)
- Diagramy procesów biznesowych (podrozdział 5.7)
- Diagram stanów (podrozdział 5.9)
- Diagram bazy danych (podrozdział 5.10)

4 Analiza rynku

Rosnąca ilość danych i dokumentów cyfrowych sprawia, że organizacje muszą zmieniać podejście do ich przechowywania, organizacji i przetwarzania. Tradycyjne metody zarządzania informacją przestają być wystarczające, co prowadzi do rosnącego zapotrzebowania na systemy klasy DMS (Document Management System). Rozwiązania te umożliwiają nie tylko archiwizację dokumentów, ale również ich wersjonowanie, wyszukiwanie, kontrolę dostępu oraz automatyzację obiegu informacji.

Rynek systemów DMS jest obecnie bardzo zróżnicowany i dynamicznie się rozwija, obejmując zarówno lekkie, często otwartoźródłowe aplikacje przeznaczone dla małych firm lub indywidualnych użytkowników, jak i zaawansowane platformy klasy enterprise, oferujące szeroki zakres funkcji integracyjnych, skalowalność oraz wysoki poziom bezpieczeństwa. W niniejszej analizie zestawiono główne podejścia do projektowania systemów DMS: rozwiązania minimalistyczne, skoncentrowane na prostocie i łatwości wdrożenia, oraz rozbudowane systemy korporacyjne, dostosowane do potrzeb dużych organizacji i złożonych procesów biznesowych.

4.1 Paperless-ngx

[Paperless-ngx](#) to nowoczesny, otwartoźródłowy system zarządzania dokumentami, ukierunkowany na automatyzację procesu digitalizacji, klasyfikacji i archiwizacji plików. Projekt jest aktywnie rozwijany przez społeczność, która dostarcza również dodatkowe aplikacje desktopowe i mobilne, rozszerzające jego możliwości. System został zaprojektowany z myślą o użytkownikach indywidualnych oraz małych organizacjach, oferując prostotę wdrożenia przy jednoczesnym zachowaniu istotnych funkcji zarządzania dokumentami.

Stos technologiczny: Python — Django — Angular — PostgreSQL

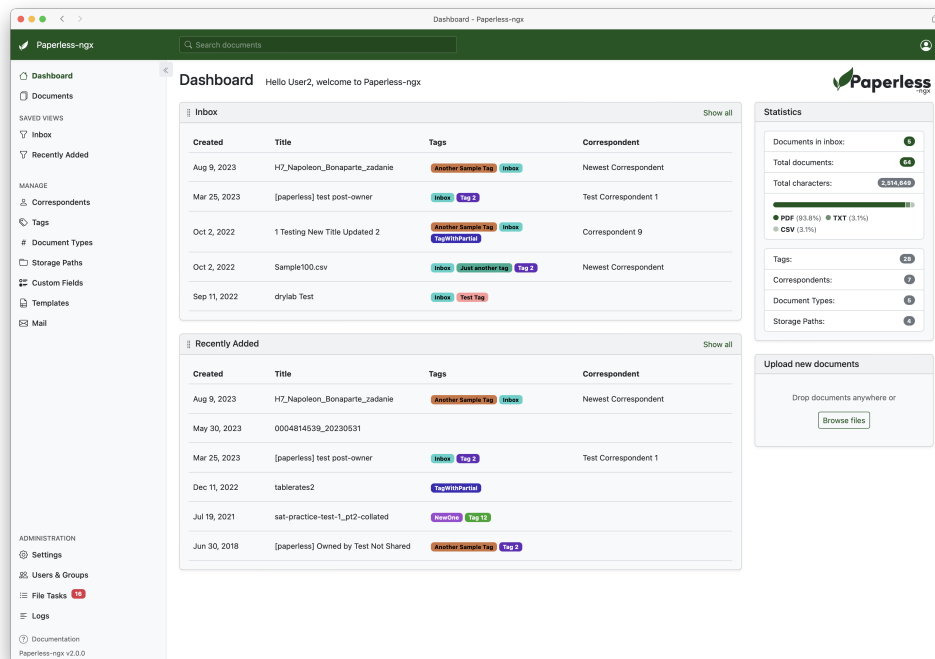
4.1.1 Główne cechy

- Automatyczne przetwarzanie dokumentów z wykorzystaniem technologii OCR, umożliwiające ekstrakcję treści z plików graficznych i PDF.
- Mechanizmy inteligentnego tagowania dokumentów oparte na modelach klasyfikacyjnych.
- Integracja z narzędziami do akwizycji dokumentów, takimi jak poczta elektroniczna oraz monitorowane katalogi systemowe.
- Wsparcie dla wyszukiwania pełnotekstowego w zgromadzonych zasobach.
- Przeglądarkowy interfejs użytkownika zaprojektowany z naciskiem na użyteczność i prostotę obsługi.
- Możliwość lokalnego wdrożenia systemu (self-hosting), zapewniająca pełną kontrolę nad danymi.
- Rozszerzalna architektura systemu dzięki udokumentowanemu interfejsowi API.


4.1.2 Ograniczenia

- Brak zaawansowanego mechanizmu zarządzania przepływem pracy (workflow), w szczególności ograniczone możliwości modelowania procesów biznesowych.
- Ograniczony system kontroli dostępu, niewspierający szczegółowych (granularnych) polityk uprawnień.

- Brak natywnej obsługi zaawansowanych integracji z zewnętrznymi systemami informatycznymi.
- Ograniczone możliwości definiowania i konfiguracji schematów metadanych dokumentów.
- Brak rozbudowanych mechanizmów wersjonowania dokumentów, istotnych w środowiskach wieloetapowej edycji.



Rys. 4.1. Paperless-ngx - Panel główny



Rys. 4.2. Paperless-ngx - Spis dokumentów

4.2 OpenKM

OpenKM to zaawansowany system zarządzania dokumentami klasy enterprise, dostępny zarówno w wersji open-source, jak i komercyjnej. Platforma jest przeznaczona dla średnich i dużych przedsiębiorstw, które wymagają rozbudowanych mechanizmów zarządzania treścią, obiegiem dokumentów oraz integracji z istniejącą infrastrukturą IT. System wspiera pełen cykl życia dokumentu – od jego rejestracji, poprzez przetwarzanie i dystrybucję, aż po archiwizację – zgodnie z przyjętymi standardami, takimi jak ISO-15489.


Stos technologiczny: Java — GWT — Hibernate — Apache Tomcat — MySQL / PostgreSQL

4.2.1 Główne cechy


- Zaawansowane zarządzanie dokumentami oraz rozbudowane modele metadanych.
- Obsługa procesów workflow umożliwiającą modelowanie i automatyzację obiegu dokumentów.
- Mechanizmy automatycznego tagowania dokumentów oparte na regułach biznesowych.
- Wbudowany system wersjonowania dokumentów, wspierający kontrolę zmian i historię edycji.
- Możliwość podpisywania dokumentów (w tym wsparcie dla podpisów elektronicznych).
- Integracja z systemami zewnętrznymi (np. ERP, CRM).
- Rozbudowany system zarządzania użytkownikami oraz szczegółowa kontrola uprawnień.
- Dostępność w modelu chmurowym oraz on-premise.
- Wsparcie dla audytu, monitorowania oraz zgodności z wymaganiami organizacyjnymi.

4.2.2 Ograniczenia

- Przestarzałe technologie frontendowe (utrudniona rozbudowa UI).
- Wysoka złożoność architektury (trudniejsza modyfikacja i utrzymanie).
- Duże wymagania zasobowe przy skalowaniu.
- Ograniczona elastyczność w dostosowaniu UI bez ingerencji w kod.



Rys. 4.3. OpenKM - Spis dokumentów i podgląd



Rys. 4.4. OpenKM - Tworzenie nowego przepływu

4.3 M-Files

M-Files to nowoczesny system zarządzania informacją (Information Management System), który odchodzi od klasycznego podejścia DMS opartego na strukturze folderów, na rzecz modelu bazującego na metadanych oraz kontekście biznesowym. System integruje się z ekosystemem Microsoft oraz wykorzystuje mechanizmy sztucznej inteligencji do wspomagania zarządzania dokumentami, automatyzacji procesów oraz analizy treści. Dzięki zastosowaniu konfigurowalnych metadanych, workflow oraz polityk zarządzania, M-Files dostosowuje się do zmieniających się potrzeb organizacji.

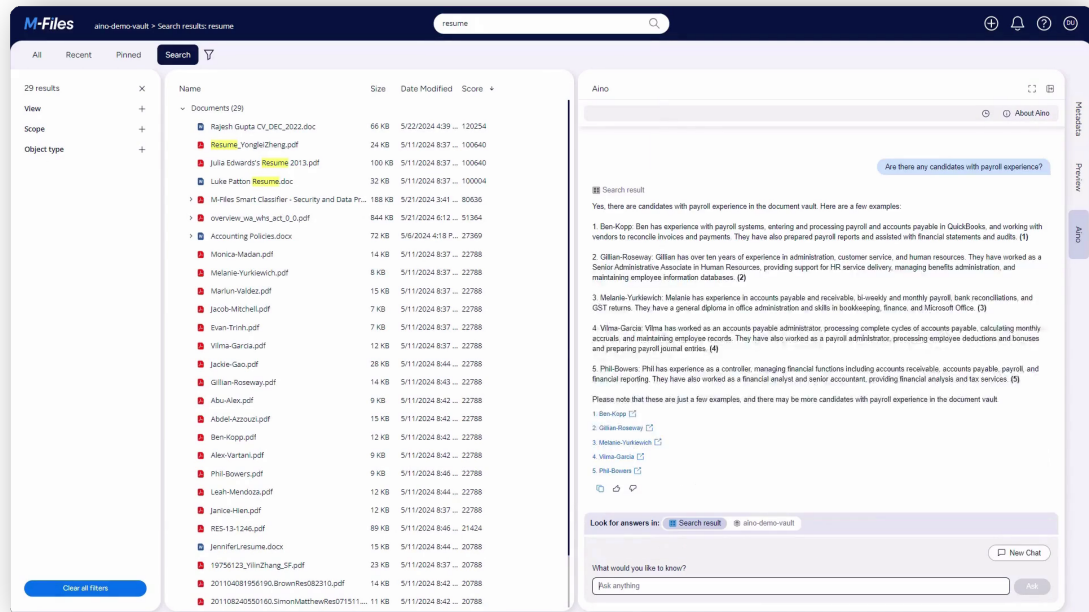
Stos technologiczny: .NET — Azure — Microsoft Graph

4.3.1 Główne cechy


- Organizacja dokumentów oparta na metadanych, umożliwiającą powiązanie plików z kontekstem biznesowym (np. projekty, klienci, zasoby).
- Dynamiczne widoki danych, zastępujące statyczną strukturę folderów i dostosowujące się do potrzeb użytkownika.
- Zaawansowane wyszukiwanie pełnotekstowe oraz kontekstowe.
- Wbudowane mechanizmy wersjonowania dokumentów, zapewniające śledzenie zmian i historii edycji.
- Obsługa obiegów dokumentów (workflow) wraz z możliwością automatyzacji procesów biznesowych.
- Ścisła integracja z narzędziami ekosystemu Microsoft (m.in. Microsoft 365, SharePoint, Teams).
- Wsparcie dla wyszukiwania w języku naturalnym.
- Wykorzystanie mechanizmów AI do generowania podsumowań dokumentów.
- System rekomendacji sugerujący powiązane dokumenty i informacje.
- Automatyczne uzupełnianie treści oraz metadanych na podstawie analizy dokumentów.

4.3.2 Ograniczenia

- Brak dostępnej wersji open-source.
- Wysoki próg wejścia związany z koniecznością konfiguracji modeli metadanych na etapie wdrożenia.
- Silna zależność od ekosystemu Microsoft, ograniczająca niezależność technologiczną.
- Ograniczona elastyczność w środowiskach spoza infrastruktury Microsoft.



Rys. 4.5. MFiles - Spis dokumentów i wynik zapytania w języku naturalnym



Rys. 4.6. MFiles - Tworzenie nowego dokumentu

4.4 Wnioski

Rynek systemów DMS rozwija się dynamicznie, napędzany rosnącą potrzebą digitalizacji oraz automatyzacji procesów biznesowych. Analizowane rozwiązania reprezentują odmienne podejścia do projektowania systemów zarządzania dokumentami.

- Paperless-ngx odpowiada na potrzeby użytkowników indywidualnych oraz małych i średnich organizacji, oferując prostotę wdrożenia oraz podstawowe mechanizmy automatyzacji.
- OpenKM stanowi przykład rozwiązania klasy enterprise, zapewniającego rozbudowane funkcjonalności, wysoką skalowalność oraz szerokie możliwości integracji z innymi systemami.
- Z kolei M-Files prezentuje nowoczesne podejście do zarządzania informacją, w którym kluczową rolę odgrywają metadane oraz mechanizmy sztucznej inteligencji wspierające organizację i analizę dokumentów.

Na podstawie przeprowadzonej analizy można zauważyć istotną lukę rynkową. Brakuje rozwiązania, które łączyłoby prostotę i lekkość systemów takich jak Paperless-ngx z zaawansowanymi funkcjami wykorzystującymi sztuczną inteligencję, przy jednoczesnym zachowaniu niezależności od zewnętrznych dostawców usług. Istnieje zatem przestrzeń dla systemu DMS, który oferowałby nowoczesne mechanizmy AI w formie zintegrowanej, przy zachowaniu elastyczności, kontroli nad danymi oraz relatywnie niskiej złożoności wdrożenia.

5 Projekt systemu

Wymagania funkcjonalne określają funkcje i operacje, które system musi realizować, aby umożliwić użytkownikom korzystanie z jego możliwości. Opisują sposób interakcji użytkownika z aplikacją oraz działania wykonywane przez system. Stanowią podstawę do projektowania architektury i implementacji systemu. Uzupełnieniem są wymagania нефunkcjonalne, które określają parametry jakościowe, takie jak wydajność, bezpieczeństwo, użyteczność oraz kompatybilność z różnymi środowiskami.

5.1 Specyfikacja wymagań funkcjonalnych

5.1.1 Dodawanie zasobów

System umożliwia użytkownikowi przesyłanie plików do repozytorium systemu. Obsługiwane są formaty plików graficznych (np. JPG, PNG), plików tekstowych (TXT) oraz dokumentów PDF. Podczas przesyłania zasobów użytkownik może dodać krótki opis przesłanych plików. Użytkownik może dodawać pojedyncze pliki lub wiele plików jednocześnie. System umożliwia także przesłanie archiwum ZIP, które zostanie automatycznie rozpakowane, a znajdujące się w nim pliki zostaną dodane do systemu. Pliki znajdujące się w archiwum ZIP, które nie są obsługiwane przez system, zostają automatycznie odrzucone i nie są dodawane do repozytorium. Podczas dodawania plików system wykrywa duplikaty na podstawie ich zawartości i informuje użytkownika o ich istnieniu. W przypadku wykrycia duplikatu użytkownik może zdecydować, czy plik ma zostać zapisany jako nowa wersja istniejącego dokumentu, czy jako osobny zasób.

5.1.2 Wyszukiwanie zasobów

System umożliwia wyszukiwanie dokumentów zgromadzonych w repozytorium. Użytkownik może wyszukiwać dokumenty przy użyciu zapytań w języku naturalnym, korzystając z wyszukiwania semantycznego. System pozwala także na dokładne wyszukiwanie fraz w nazwie pliku, opisie oraz w zawartości tekstowej dokumentów. Dodatkowo system umożliwia wyszukiwanie dokumentów podobnych do wskazanego pliku na podstawie analizy jego treści.

5.1.3 Filtrowanie i sortowanie zasobów

System umożliwia filtrowanie zasobów podczas przeglądania repozytorium. Użytkownik może zawęzić listę dokumentów na podstawie wybranych kryteriów, takich jak typ lub format pliku, przypisane kategorie, tagi oraz zakres daty dodania. System umożliwia również sortowanie wyników przeglądania dokumentów, na przykład według daty dodania lub innych dostępnych parametrów, co ułatwia odnajdywanie i organizowanie zasobów.

5.1.4 Zarządzanie kategoriami i tagami

System umożliwia użytkownikowi zarządzanie kategoriami oraz tagami przypisywanymi do dokumentów. Użytkownik może dodawać, edytować oraz usuwać kategorie i tagi w dedykowanym widoku zarządzania. System pozwala również na tworzenie nowych kategorii i tagów bezpośrednio podczas przypisywania ich do dokumentów. Dzięki temu użytkownik może łatwo organizować i klasyfikować zasoby w repozytorium.

5.1.5 Zarządzanie zasobami

System umożliwia użytkownikowi edycję metadanych dokumentów znajdujących się w repozytorium. Użytkownik może zmienić nazwę dokumentu, jego opis, przypisaną kategorię oraz tagi. System umożliwia również zarządzanie wersjami dokumentów – użytkownik może przeglądać historię wersji, przywracać wcześniejsze wersje oraz wskazywać wersję aktualnie obowiązującą. System pozwala także na usuwanie dokumentów – zarówno pojedynczych plików, jak i wielu dokumentów jednocześnie, na przykład wszystkich przypisanych do wybranej kategorii lub oznaczonych określonym tagiem.

5.1.6 Udostępnianie i zarządzanie udostępnieniami zasobów

System umożliwia użytkownikowi udostępnianie wybranych dokumentów innym użytkownikom systemu lub osobom zewnętrznym poprzez wygenerowanie specjalnego linku dostępowego. System pozwala również na zarządzanie udostępnieniami. Użytkownik może przeglądać listę aktywnych udostępnień dla swoich dokumentów, zmieniać ich ustawienia oraz w dowolnym momencie wycofać udostępnienie, co powoduje utratę dostępu do dokumentu przez osoby, którym został on udostępniony.

5.1.7 Kontrola wersji i wykrywanie duplikatów zasobów

System umożliwia przechowywanie i zarządzanie wersjami dokumentów. Każda modyfikacja pliku może zostać zapisana jako nowa wersja, przy zachowaniu historii zmian oraz możliwości przywrócenia wcześniejszych wersji dokumentu. System wykrywa również duplikaty przesyłanych plików na podstawie ich zawartości, informując użytkownika o istniejącej kopii. Użytkownik ma możliwość zdecydowania, czy nowy plik ma zostać zapisany jako nowa wersja istniejącego dokumentu, czy jako osobny zasób.

5.1.8 Pobieranie zasobów z opcjonalną konwersją formatu

System umożliwia użytkownikowi pobieranie zasobów, zarówno własnych, jak i udostępnionych przez innych użytkowników. Podczas pobierania użytkownik może wybrać zapis pliku w innym formacie niż oryginalny – system automatycznie dokona konwersji pliku.

5.1.9 Generowanie miniaturk zasobów

System automatycznie generuje miniaturki dla wszystkich typów dokumentów w repozytorium, ułatwiając ich szybkie przeglądanie. Pliki graficzne są skalowane do niskiej rozdzielczości, dokumenty PDF są renderowane tak, że miniaturka przedstawia pierwszą stronę, a pliki tekstowe są konwertowane i renderowane w formie graficznej podobnie jak PDF.

5.1.10 Autoryzacja i uwierzytelnianie użytkowników

System zapewnia standardowe funkcje logowania i rejestracji użytkowników. Użytkownicy mogą stworzyć konto w systemie lub logować się przy użyciu mechanizmów jednokrotnego logowania (SSO). System weryfikuje poprawność danych logowania i chroni dostęp do zasobów cyfrowych, zapewniając bezpieczeństwo.

5.2 Specyfikacja wymagań niefunkcjonalnych

5.2.1 Wydajność (dla bazy zawierającej do 1000 dokumentów)

- Czas wyszukiwania klasycznego: poniżej 1 sekundy.
- Czas wyszukiwania semantycznego: poniżej 2 sekund.

5.2.2 Pojemność

- System musi obsługiwać minimum 1000 dokumentów.
- Maksymalny rozmiar pojedynczego pliku: 50 MB.
- Maksymalny rozmiar archiwum ZIP: 250 MB.

5.2.3 Bezpieczeństwo

- Dostęp do systemu wymaga uwierzytelnienia użytkownika.
- Użytkownik ma dostęp wyłącznie do swoich dokumentów oraz dokumentów, które zostały mu udostępnione.

5.2.4 Kompatybilność

- Aplikacja webowa musi działać poprawnie i płynnie w przeglądarkach: Firefox 120 lub nowsza, Chromium 120 lub nowsza, Edge 120 lub nowsza.

5.2.5 Użyteczność

- Interfejs użytkownika powinien umożliwiać wykonanie podstawowych operacji (np. przesyłanie dokumentów, wyszukiwanie) w maksymalnie trzech krokach.


5.3 Hierarchiczny model funkcji

Diagram Hierarchii Funkcji (ang. *Function Hierarchy Diagram, FHD*) przedstawia funkcjonalności systemu w postaci hierarchicznej struktury, rozpoczynającej się od głównego celu systemu, a następnie rozwijanej na coraz bardziej szczegółowe funkcje i podfunkcje. Diagram umożliwia przeprowadzenie dekompozycji funkcjonalnej systemu, co ułatwia identyfikację wszystkich wymaganych funkcji oraz określenie zależności pomiędzy nimi.

W projektowanym systemie diagram FHD przedstawia podział głównej funkcjonalności systemu na kluczowe obszary odpowiedzialne za obsługę dokumentów oraz użytkowników. Na najwyższym poziomie znajduje się system DMS z wyszukiwaniem semantycznym, natomiast kolejne poziomy diagramu prezentują najważniejsze grupy funkcji, takie jak zarządzanie zasobami, wyszukiwanie i przeglądanie dokumentów, zarządzanie kategoriami i tagami, pobieranie i konwersja dokumentów, prezentacja zasobów, udostępnianie dokumentów oraz zarządzanie użytkownikami.

Poszczególne obszary zostały następnie rozwinięte o bardziej szczegółowe funkcjonalności. Przykładowo moduł zarządzania zasobami obejmuje dodawanie dokumentów, edycję metadanych, kontrolę wersji oraz usuwanie zasobów. Moduł wyszukiwania umożliwia realizację wyszukiwania dokładnego, semantycznego oraz wyszukiwania podobnych dokumentów. Diagram uwzględnia również funkcje związane z generowaniem miniatur dokumentów, konwersją formatów plików, udostępnianiem zasobów za pomocą linków oraz zarządzaniem kontami użytkowników.

Diagram hierarchii funkcji dla projektowanego systemu przedstawiono na *rysunku 5.1*.



Rys. 5.1. Diagram hierarchii funkcji

5.4 Historyjki użytkowników

Historyjki użytkowników (ang. *User Stories*) są jedną z technik wykorzystywanych do opisywania wymagań funkcjonalnych systemu z perspektywy jego użytkowników. Pozwalają one określić oczekiwania oraz potrzeby poszczególnych aktorów w sposób zrozumiały zarówno dla projektantów systemu, jak i jego przyszłych użytkowników. Historyjki użytkowników wspomagają proces identyfikacji funkcjonalności systemu oraz stanowią podstawę do definiowania wymagań funkcjonalnych.

W projektowanym systemie zarządzania dokumentami historyjki użytkowników zostały pogrupowane według obszarów funkcjonalnych odpowiadających najważniejszym funkcjom systemu.

5.4.1 Rejestracja i uwierzytelnianie użytkowników

1. Jako gość chcę się zarejestrować w aplikacji.
2. Jako gość chcę zalogować się do aplikacji loginem i hasłem.
3. Jako gość chcę zalogować się do aplikacji przez konto Google.

5.4.2 Dodawanie dokumentów

4. Jako użytkownik chcę przesłać jeden lub kilka plików i móc ustawić ich nazwy, kategorie i tagi w trakcie.
5. Jako użytkownik chcę przesłać wiele plików w formie archiwum ZIP.

5.4.3 Przeglądanie dokumentów

6. Jako użytkownik chcę przeglądać moje dokumenty z widocznymi miniaturkami, nazwami, tagami i kategoriami.
7. Jako użytkownik chcę kontrolować sortowanie i filtrowanie podczas przeglądania.
8. Jako użytkownik chcę wyświetlić podgląd pliku graficznego, tekstowego i PDF.

5.4.4 Wyszukiwanie dokumentów

9. Jako użytkownik chcę wyszukiwać dokumenty pełnotekstowo.
10. Jako użytkownik chcę wyszukiwać dokumenty podobne semantycznie do zapytania tekstowego.
11. Jako użytkownik chcę wyszukiwać dokumenty podobne semantycznie do wskazanego dokumentu.

5.4.5 Zarządzanie dokumentami i metadanymi

12. Jako użytkownik chcę dodać nową kategorię lub tag o określonej nazwie.
13. Jako użytkownik chcę zmienić kategorie i tagi przypisane do dokumentu.
14. Jako użytkownik chcę zmienić nazwę i opis dokumentu.
15. Jako użytkownik chcę usunąć dokument.

5.4.6 Pobieranie i konwersja dokumentów

16. Jako użytkownik chcę pobrać dokument w oryginalnej formie.
17. Jako użytkownik chcę pobrać dokument graficzny w innym formacie.
18. Jako użytkownik chcę pobrać w formacie PDF dokument, który w oryginale jest DOCX.

5.4.7 Udostępnianie dokumentów

19. Jako użytkownik chcę udostępnić dokument w formie linku.
20. Jako gość chcę zobaczyć podgląd i pobrać (z takimi samymi opcjami jak wyżej) dokument udostępniony mi przez link.
21. Jako użytkownik chcę zobaczyć status udostępnienia dokumentu.
22. Jako użytkownik chcę zobaczyć listę wszystkich udostępnionych dokumentów.
23. Jako użytkownik chcę wycofać udostępnienie dokumentu, unieważniając link.

Przedstawione historyjki użytkowników opisują najważniejsze funkcjonalności projektowanego systemu z perspektywy jego użytkowników. Stanowią one podstawę do dalszego definiowania wymagań funkcjonalnych oraz projektowania poszczególnych elementów systemu.

5.5 Scenariusze przypadków użycia

5.5.1 Pobieranie dokumentu z konwersją do formatu PDF.

Opis: Scenariusz przypadku użycia opisuje proces wyszukania dokumentu w repozytorium, wyświetlenia jego szczegółów oraz pobrania go w formacie innym niż oryginalny.

Aktorzy: Użytkownik.

Warunki początkowe: Użytkownik jest zalogowany do systemu. Dokument znajduje się w repozytorium systemu.

Warunki końcowe: Dokument zostaje pobrany przez użytkownika w formacie PDF.

Przebieg główny:

1. Użytkownik otwiera widok repozytorium dokumentów.
2. Użytkownik wyszukuje dokument przy użyciu wyszukiwania dokładnego.
3. System wyświetla listę znalezionych dokumentów.
4. Użytkownik wybiera dokument zapisany w formacie DOCX.
5. System wyświetla szczegóły dokumentu.
6. Użytkownik wybiera opcję „Pobierz”.
7. System wyświetla dostępne formaty pobierania.
8. Użytkownik wybiera format PDF.
9. System przygotowuje plik do pobrania.
10. System rozpoczyna pobieranie dokumentu.
11. Użytkownik zapisuje plik PDF na swoim urządzeniu.

Rozszerzenia:

2a. Nie znaleziono dokumentów spełniających kryteria wyszukiwania

1. System wyświetla komunikat o braku wyników.
2. Użytkownik modyfikuje zapytanie wyszukiwania.

5.5.2 Udostępnianie dokumentu po wyszukiwaniu semantycznym

Opis: Scenariusz przypadku użycia opisuje proces odnalezienia dokumentu przy użyciu wyszukiwania semantycznego oraz udostępnienia go innemu użytkownikowi poprzez wygenerowanie linku dostępowego.

Aktorzy: Użytkownik.

Warunki początkowe: Użytkownik jest zalogowany do systemu. Dokument znajduje się w repozytorium.

Warunki końcowe: Wygenerowany zostaje aktywny link umożliwiający dostęp do dokumentu.

Przebieg główny:

1. Użytkownik otwiera widok repozytorium dokumentów.
2. Użytkownik wprowadza zapytanie w języku naturalnym.
3. System wykonuje wyszukiwanie semantyczne.
4. System wyświetla listę dokumentów najbardziej podobnych do zapytania.
5. Użytkownik wybiera dokument z listy wyników.
6. System wyświetla szczegóły dokumentu.
7. Użytkownik wybiera opcję „Udostępnij”.
8. System generuje unikalny link dostępu do dokumentu.
9. System zapisuje informacje o udostępnieniu.
10. System wyświetla wygenerowany link.
11. Użytkownik przekazuje link wybranej osobie.

Rozszerzenia:

4a. Nie znaleziono dokumentów podobnych do zapytania

1. System wyświetla komunikat o braku wyników.
2. Użytkownik modyfikuje treść zapytania.

8a. Dokument jest już udostępniony

1. System informuje użytkownika o istniejącym aktywnym udostępnieniu.
2. System wyświetla wcześniej wygenerowany link.


11a. Użytkownik chce wycofać udostępnienie

1. Użytkownik otwiera listę aktywnych udostępnień.
2. Użytkownik wybiera opcję „Cofnij dostęp”.
3. System unieważnia link dostępu.
4. System zapisuje zmianę statusu udostępnienia.


5.6 Diagramy przypadków użycia

Diagramy przypadków użycia (ang. *Use Case Diagrams*) w języku UML służą do modelowania funkcjonalności systemu z perspektywy jego użytkowników (aktorów). Pozwalają one określić zakres projektowanego rozwiązania oraz operacje dostępne dla poszczególnych grup użytkowników. W systemie DMS funkcjonalności te zostały podzielone na powiązane obszary tematyczne na podstawie zdefiniowanych wymagań funkcjonalnych.

W kolejnych podrozdziałach przedstawiono diagramy przypadków użycia dla najważniejszych obszarów funkcjonalnych systemu.




20




Rys. 5.3. Zarządzanie użytkownikami

Na rysunku 5.3 przedstawiono funkcjonalności związane z obsługą kont użytkowników. Diagram obejmuje procesy rejestracji, logowania oraz uwierzytelniania użytkowników. Dodatkowo użytkownik może zarządzać swoim profilem oraz przeprowadzić dezaktywację konta. W przypadku pomyślnego uwierzytelnienia system nadaje użytkownikowi odpowiednie uprawnienia dostępu do zasobów.




Rys. 5.4. Prezentacja i pobieranie zasobów

Operacje przedstawione na rysunku 5.4 dotyczą przeglądania dokumentów zgromadzonych w repozytorium oraz ich pobierania. Użytkownik ma możliwość wyświetlenia listy dokumentów, przejścia do szczegółów wybranego zasobu oraz pobrania jego aktualnej lub historycznej wersji. Diagram uwzględnia również funkcję konwersji dokumentów do innych formatów podczas procesu pobierania.




Rys. 5.5. Udostępnianie zasobów

Na rysunku 5.5 przedstawiono przypadki użycia związane z udostępnianiem dokumentów osobom trzecim. Użytkownik może generować linki dostępu do wybranych zasobów oraz zarządzać wcześniej utworzonymi udostępnieniami. Diagram obejmuje również możliwość cofnięcia dostępu poprzez unieważnienie wygenerowanego linku.



Rys. 5.6. Wyszukiwanie i przeglądanie zasobów

Rysunek 5.6 przedstawia funkcjonalności odpowiedzialne za odnajdywanie dokumentów w systemie. Użytkownik może korzystać z mechanizmów filtrowania i sortowania wyników, a także realizować wyszukiwanie dokładne oraz wyszukiwanie semantyczne. Diagram uwzględnia również funkcję wyszukiwania podobnych dokumentów oraz możliwość przeglądania wcześniejszych wersji wybranego zasobu.




Rys. 5.7. Zarządzanie kategoriami i tagami

Na rysunku 5.7 przedstawiono przypadki użycia związane z organizacją dokumentów za pomocą kategorii i tagów. Użytkownik posiada możliwość przeglądania, dodawania, edycji oraz usuwania kategorii i tagów. Funkcjonalności te wspierają porządkowanie zasobów oraz usprawniają proces ich wyszukiwania i klasyfikacji.

5.7 Diagramy procesów biznesowych


Diagramy wykonane w notacji BPMN (ang. *Business Process Model and Notation*) służą do graficznego przedstawienia sekwencji zadań i przepływu informacji w ramach realizowanych procesów. Pozwalają one na precyzyjne odzwierciedlenie interakcji pomiędzy warstwą wizualną aplikacji, logiką biznesową a zewnętrznymi modułami i usługami składowymi.

W poniższym podrozdziale zaprezentowano oraz opisano kluczowe procesy zachodzące wewnątrz systemu DMS podczas obsługi dokumentów i realizacji zaawansowanych funkcji wyszukiwania.



Rys. 5.8. Diagram procesu wyszukiwania semantycznego


Na rysunku 5.8 przedstawiono proces wyszukiwania semantycznego plików. Użytkownik wprowadza zapytanie tekstowe w warstwie interfejsu (Frontend). Następnie system DMS weryfikuje dostępność zewnętrznego modułu sztucznej inteligencji (AI Inference). Jeśli moduł nie odpowiada, użytkownik otrzymuje komunikat o niedostępności usługi. W przypadku poprawnego działania, na podstawie zapytania obliczany jest wektor kwerendy, który backend wykorzystuje do odnalezienia w bazie danych dokumentów o zbliżonym znaczeniu kontekstowym. Proces kończy się zbudowaniem listy rezultatów i wyświetleniem ich na ekranie.



Rys. 5.9. Diagram procesu generowania embedding wektora


Proces zaprezentowany na rysunku 5.9 dotyczy asynchronicznego generowania wektora reprezentacji semantycznej (embeddingu) po odebraniu identyfikatora pliku. Moduł backendowy wysyła żądanie wykonania obliczeń do serwisu AI, który pobiera pełną zawartość wskazanego dokumentu.

Po pomyślnym odczytaniu danych moduł sztucznej inteligencji oblicza wektor semantyczny tekstu i odsyła go do backendu. Zwieńczeniem procesu jest trwale zapisanie wektora w bazie danych, co umożliwia późniejsze inteligentne wyszukiwanie dokumentów.




Rys. 5.10. Diagram procesu zapisu dokumentu

Na rysunku 5.10 zobrazowano wewnętrzny proces zapisu nowego dokumentu wraz z powiązаныmi metadanymi. Po odebraniu pliku system DMS weryfikuje poprawność jego formatu. W przypadku wykrycia nieobsługiwanego rozszerzenia proces jest przerywany. Pozytywna walidacja skutkuje fizycznym zapisaniem pliku w magazynie obiektowym S3 oraz jednoczesnym zarejestrowaniem metadanych w relacyjnej bazie danych. W celu optymalizacji działania aplikacji, dokument zostaje następnie przekazany do dwóch niezależnych kolejek: kolejki indeksowania treści oraz kolejki odpowiedzialnej za generowanie miniatur podglądu.



Rys. 5.11. Diagram procesu wysyłania archiwum ZIP

Rysunek 5.11 przedstawia algorytm masowego importu dokumentów spakowanych do archiwum ZIP. Użytkownik wskazuje spakowany plik w interfejsie graficznym, skąd zostaje on przesłany do backendu systemu DMS. Serwer aplikacji rozpakowuje archiwum i analizuje strukturę wyodrębnionych katalogów. Dla każdego poprawnego pliku uruchamiany jest jednostkowy proces zapisu dokumentu w repozytorium. Po przetworzeniu wszystkich obiektów warstwa interfejsu generuje i wyświetla użytkownikowi podsumowanie masowego importu.




Rys. 5.12. Diagram procesu pobierania i konwersji dokumentu

Na rysunku 5.12 przedstawiono proces pobierania plików, który może zostać rozszerzony o ich dynamiczną konwersję. Po wybraniużądanegodokumentu i określeniu formatu docelowego, backend weryfikuje dostępność pliku. Następnie system DMS pobiera oryginalny dokument z magazynu obiektowego S3. Jeśli użytkownik zażądał zmiany rozszerzenia, plik jest przetwarzany w locie przez moduł konwersji. Gotowy dokument zostaje przesłany do warstwy interfejsu i zapisany na dysku lokalnym klienta.


5.8 Diagramy przepływu danych

Diagramy przepływu danych (ang. *Data Flow Diagram* – DFD) służą do graficznego przedstawienia obiegu informacji w systemie DMS. Pozwalają one zidentyfikować zewnętrzne podmioty (aktorów), procesy przetwarzające informacje oraz miejsca ich trwałego przechowywania (magazyny danych).



Rys. 5.13. Poziomy diagram DFD

Na rysunku 5.13 przedstawiono poziomy diagram DFD, który obrazuje ogólny kontekst systemu DMS oraz interakcje z zewnętrznymi aktorami: zarejestrowanym użytkownikiem oraz gościem. Zalogowany użytkownik wymienia z systemem informacje takie jak dane rejestracyjne i logowania, zapytania (dokładne i semantyczne) oraz przesyła pliki i archiwa, otrzymując w zamian wyniki wyszukiwania, czy pobierane dokumenty. Rola gościa koncentruje się na dostępie do współdzielonych plików za pomocą dedykowanych linków dostępowych.



Rys. 5.14. Poziom 1 diagramu DFD

Na rysunku 5.14 zaprezentowano szczegółowy poziom 1 diagramu DFD, który dekomponuje system DMS na konkretne procesy funkcjonalne oraz wskazuje powiązane z nimi magazyny danych. W strukturze przechowywania informacji wydzielono trzy komponenty: Bazę Relacyjną (metadane dokumentów oraz dane użytkowników), Bazę Wektorową (obliczone wektory semantyczne) oraz Magazyn S3 (pliki źródłowe oraz miniatury).

Należy zaznaczyć, że przedstawiony podział ma charakter logiczny i został zastosowany w celu zwiększenia czytelności diagramu. W rzeczywistej implementacji systemu funkcje bazy relacyjnej oraz bazy wektorowej realizowane będą przez pojedynczą instancję bazy danych PostgreSQL wykorzystującą rozszerzenie pgvector. Oznacza to, że zarówno metadane dokumentów, jak i reprezentacje wektorowe wykorzystywane podczas wyszukiwania semantycznego będą przechowywane w jednym systemie bazodanowym, natomiast fizyczne pliki dokumentów oraz miniatury pozostaną zapisane w magazynie obiektowym S3.

W ramach poziomu 1 wyszczególniono następujące procesy:


- **Rejestracja i uwierzytelnianie** – odpowiada za obsługę danych logowania i rejestracji użytkownika oraz zarządzanie tokenami sesji w oparciu o odczyt i zapis danych w Bazie Relacyjnej.
- **Dodawanie plików** – przyjmuje od użytkownika dokumenty lub archiwa, zapisuje ich meta-

dane w Bazie Relacyjnej, przekazuje pliki do Magazynu S3 oraz przekierowuje je do dalszego przetwarzania.

- **Udostępnianie dokumentów** – realizuje żądania udostępniania lub wycofywania dostępu, generuje linki dla gości i weryfikuje ich ważność na podstawie danych z Bazy Relacyjnej.
- **Pobieranie i konwersja** – pobiera dokumenty z Magazynu S3 i dostarcza je użytkownikowi, w razie potrzeby wykonując konwersję formatu.
- **Wyszukiwanie dokładne** – przetwarza zapytania tekstowe użytkownika i przeszukuje metadane zapisane w Bazie Relacyjnej.
- **Wyszukiwanie semantyczne** – realizuje zapytania kontekstowe poprzez porównywanie wektorów i odpytywanie Bazy Wektorowej.
- **Generowanie miniaturk oraz wektorów osadzenia** – procesy pomocnicze; pierwszy generuje miniatury obrazów, plików tekstowych i PDF do Magazynu S3, natomiast drugi współpracuje z zewnętrznym modułem AI Inference w celu wyznaczenia wektora osadzenia (embeddingu) i zapisania go w Bazie Wektorowej.

5.9 Diagram stanów

Diagram stanów (ang. *State Machine Diagram*) służy do przedstawienia pełnego cyklu życia dokumentu w systemie DMS, obrazując możliwe stany obiektu oraz zdarzenia powodujące ich zmianę.



Rys. 5.15. Diagram stanów dokumentu


Na rysunku 5.15 zaprezentowano cykl przetwarzania dokumentu od momentu jego wprowadzenia do systemu DMS. Pierwszym stanem jest *Plik przyjęty*, w którym następuje walidacja formatu. W przypadku wykrycia błędnego rozszerzenia (zły format) proces zostaje przerwany.

Po pomyślnej walidacji dokument przechodzi w stan *Oryginał zapisany*. Następnie system DMS sprawdza typ pliku – jeżeli jest to dokument biurowy (typ=Office), następuje automatyczne przejście do stanu *Przekonwertowany do PDF*. W przeciwnym wypadku plik trafia bezpośrednio do stanu *Gotowy do przetwarzania*.

Kolejny etap charakteryzuje się równoległym wykonaniem dwóch niezależnych operacji (rozwiłnienie przepływu). Dokument przechodzi jednocześnie w stan *Zaindeksowany* (odpowiedzialny za analizę semantyczną treści) oraz stan *Miniatura wygenerowana*. Po pomyślnym zakończeniu i synchronizacji obu tych procesów, dokument osiąga końcowy stan *Przetworzony*, co oznacza pełną gotowość pliku do użycia w systemie DMS.

5.10 Diagram bazy danych

Diagram ERD (ang. *Entity-Relationship Diagram*) przedstawia logiczną strukturę bazy danych systemu DMS oraz relacje pomiędzy poszczególnymi encjami. Model ten definiuje strukturę tabel, ich atrybuty, typy danych oraz powiązania za pomocą kluczy głównych i obcych, zapewniające integralność referencyjną przechowywanych informacji.



Rys. 5.16. Diagram ERD bazy danych systemu DMS

Na rysunku 5.16 zaprezentowano strukturę relacyjną bazy danych, w której centralnymi punktami systemu są encje odpowiedzialne za obsługę użytkowników oraz zarządzanie dokumentami.

Tabela *users* służy do przechowywania danych kont użytkowników systemu DMS. Powiązana jest relacją jeden-do-wielu z tabelą *user_roles*, która definiuje role oraz uprawnienia przypisane do poszczególnych osób. Każdy użytkownik może być właścicielem wielu plików, co odzwierciedla klucz obcy w tabeli *documents*.

W celu obsługi mechanizmu kontroli wersji, struktura opisu plików została rozbita na dwie kom-

plementarne encje: *documents* oraz *document_versions*. Tabela *documents* agreguje ogólne metadane dokumentu (tytuł, opis, typ, identyfikator właściciela), natomiast szczegóły techniczne dotyczące konkretnych wydań pliku znajdują się w encji *document_versions* (rozmiar, typ zawartości, stan przetworzenia). Tabela nadrzędna wskazuje na swoją aktualną rewizję poprzez relację z kluczem *latest_version_id*. W encji wersji przechowywane są również unikalne klucze obiektów (*object_keys*), które stanowią bezpośrednie wskaźniki do fizycznych plików, ich wersji prezentacyjnych oraz miniatur zapisanych w zewnętrznym magazynie obiektowym S3.

Porządkowanie i taksonomia dokumentów realizowane są przez encje *categories* oraz *tags*. Z racji tego, że jeden dokument może być przypisany do wielu kategorii lub etykiet jednocześnie, w strukturze zastosowano tabele pośredniczące *document_categories* oraz *document_tags*, realizujące relacje wiele-do-wielu.

Mechanizm bezpiecznej dystrybucji plików poza system opisuje encja *document_shares*. Przechowuje ona unikalne tokeny udostępniania, flagi widoczności publicznej, parametry blokady pobierania oraz znaczniki czasu określające ważność lub moment wycofania dostępu przez właściciela dokumentu.

Ostatni obszar bazy danych odpowiada za asynchroniczne operacje oraz moduł sztucznej inteligencji. Encja *document_job_queue* zarządza kolejką zadań systemowych (np. indeksowanie tekstu, generowanie podglądów) i śledzi status ich wykonania. Tabela *document_conversions* przechowuje wpisy o plikach poddanych transformacji do formatów alternatywnych. Z kolei tabela *pg_vector_store* odpowiada za przechowywanie embeddingów, czyli matematycznych wektorów reprezentacji semantycznej tekstu o długości 2048 komponentów, powiązanych bezpośrednio z unikalnym identyfikatorem wersji dokumentu.

Należy zaznaczyć, że przedstawiony podział na magazyn relacyjny i wektorowy ma charakter logiczny. W rzeczywistej implementacji systemu DMS funkcje tradycyjnej bazy danych oraz bazy wektorowej (tabela *pg_vector_store*) realizowane są przez pojedynczą instancję silnika PostgreSQL z wykorzystaniem rozszerzenia *pgvector*, które umożliwia sprawne nakładanie indeksów HNSW i wykonywanie zapytań opartych na podobieństwie cosinusowym. Fizyczne pliki dokumentów oraz miniatury pozostają odizolowane i zabezpieczone w magazynie S3.